UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSGRADO – FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

INFORME PARCIAL

PROYECTO DE INVESTIGACIÓN II

PLAN DE TESIS Y PROTOCOLO DE INVESTIGACIÓN

Título de tesis: Generalización de políticas de aprendizaje por refuerzo ante diferentes niveles de fidelidad de simulación

Programa: Maestría en Ciencias con mención en Inteligencia Artificial

Estudiante: Brayan Bruce Pérez Escobar

Asesora: Mtr. Ing. María Fernanda Tejada Begazo

Docente del curso: Glen Rodríguez

Lugar y fecha: Lima, noviembre de 2026

Índice

Índice 2
PARTE I. PLAN DE TESIS 5
Datos generales 5
CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA 5
1.1 Diagnóstico 5
1.1.1 Identificación y descripción del problema de estudio 6
1.1.2 Antecedentes de la investigación 6
1.1.3 Formulación del problema 7
1.1.3.1 Formulación del problema general 7
1.1.3.2 Formulación de los problemas específicos 7
1.2 Justificación y alcances 8
1.2.1 Justificación 8
1.2.2 Alcances 8
CAPÍTULO II. OBJETIVOS 8
2.1 Objetivo general 8
2.2 Objetivos específicos 9
CAPÍTULO III. MARCO TEÓRICO 9
3.1 Bases teóricas 9
3.2 Definición de términos 11
3.3 Hipótesis y variables 11
3.3.1 Hipótesis 11
3.3.2 Variables 12
CAPÍTULO IV. DISEÑO METODOLÓGICO 12
4.1 Tipo de investigación 12
4.2 Nivel de investigación 13
4.3 Métodos de trabajo 13

4.4 Población y muestra 13
4.5 Tipo de diseño 13
4.6 Técnicas e instrumentos de recolección de datos 14
4.7 Técnicas e instrumentos de análisis y procesamiento de datos 14
4.8 Etapas de intervención del estudio 14
CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS 14
5.1 Cronograma 14
5.2 Presupuesto 15
5.3 Financiamiento 15
PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL 16
6. Datos y material de estudio 16
6.1 Origen, condiciones de uso y trazabilidad 16
6.2 Estructura, diccionario de datos y análisis exploratorio 16
6.3 Ética, privacidad y seguridad 17
6.4 Preprocesamiento y control de fuga de información 17
7. Protocolo experimental 17
7.1 Preguntas de evaluación y criterios de éxito 17
7.2 Diseño de particiones y validación 18
7.3 Métricas y análisis estadístico 18
7.4 Baseline y variantes 18
7.5 Ingeniería de atributos o componentes 19
7.6 Optimización y presupuesto de búsqueda 19
7.7 Reproducibilidad y registro de experimentos 20
8. Resultados parciales y evidencia 20
8.1 Estado de implementación del pipeline 20
8.2 Comparación cuantitativa del baseline y variantes 20
8.3 Ablaciones y análisis de sensibilidad 22

8.4 Sobreajuste, errores y robustez 23
8.5 Interpretación y amenazas a la validez 24
9. Conclusiones del avance y próximos pasos 25
9.1 Conclusiones sustentadas por evidencia 25
9.2 Riesgos y plan de mitigación 26
9.3 Trabajo futuro para el siguiente sprint 26
REFERENCIAS 26
ANEXOS 28
Anexo A. Matriz de consistencia 28
Anexo D. Registro de corridas 29

PARTE I. PLAN DE TESIS

Datos generales

Tabla 1. Datos generales del plan de tesis

Campo	Información
Título del plan	Generalización de políticas de aprendizaje por refuerzo ante diferentes niveles de fidelidad de simulación
Autor	Brayan Bruce Pérez Escobar
Asesora	Mtr. Ing. María Fernanda Tejada Begazo
Unidad de posgrado y programa	Unidad de Posgrado de la Facultad de Ingeniería Industrial y de Sistemas; Maestría en Ciencias con mención en Inteligencia Artificial
Lugar o institución	Universidad Nacional de Ingeniería, Lima. El estudio es completamente computacional
Duración estimada	Diez meses: febrero de 2026 a Febrero de 2026

CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

Las políticas de aprendizaje por refuerzo (RL) para control de micro y nanorrobots se entrenan en simuladores, porque entrenarlas sobre el sistema físico es lento y costoso. Medany et al. (2025) lo muestran con un microrrobot impulsado por ultrasonido: un modelo entrenado solo con imágenes experimentales alcanzó cerca del 70 % de los objetivos después de diez días de operación continua y aun así se sobreajustó a ciertas zonas del canal, mientras que el preentrenamiento en simulación redujo el tiempo de entrenamiento y mejoró la adaptabilidad. El simulador, sin embargo, nunca reproduce toda la física del sistema donde se usará la política.

El síntoma de esa discrepancia es la caída de desempeño cuando cambia la física entre el entrenamiento y el uso. En el mismo trabajo, el modelo resolvió inicialmente solo el 50 % de las tareas en canales nuevos y necesitó 30 minutos adicionales de entrenamiento para llegar al 90 %; además, cuando apareció el flujo, la recompensa tuvo que modificarse para que los microrrobots se adhirieran a las paredes y avanzaran contra la corriente (Medany et al., 2025). La causa, según la revisión de Kirk et al. (2023), es que en RL la política se sobreajusta al entorno de entrenamiento y aprovecha regularidades que no se mantienen fuera de él. La consecuencia es que un buen resultado en un simulador simplificado no permite saber si la política funcionará con una física más completa, ni si una mejora se debe al algoritmo o a la simplificación.

La misma situación apareció en el análisis exploratorio del Sprint 1 de este proyecto. En el simulador inicial, la heurística que empuja el enjambre de lado hacia la rama objetivo entregó $\eta = 0.00$ con flujo estacionario y $\eta = 0.88$ cuando se agregó el movimiento browniano: un cambio de física invirtió el ordenamiento de las políticas. El problema no es exclusivo del caso biomédico; afecta a cualquier aplicación que entrene en simuladores de distinto costo y

fidelidad, como muestran Bhola et al. (2023) en optimización de formas aerodinámicas, donde entrenar en un solo nivel de fidelidad lleva a sobreajustarse a él.

1.1.1 Identificación y descripción del problema de estudio

El problema de estudio es la falta de una medición sistemática de cuánto y en qué dirección se degrada una política de RL cuando el nivel de fidelidad del simulador de evaluación es distinto del de entrenamiento, y de si ordenar el entrenamiento por niveles de fidelidad crecientes reduce esa degradación. El problema es de inteligencia artificial, generalización de políticas ante discrepancias del simulador, y la navegación de nanopartículas es el caso de estudio.

El sistema estudiado es un enjambre de N = 200 nanopartículas no interactuantes en un vaso bidimensional que se bifurca en Y: un canal madre de longitud 5W y dos ramas de longitud 4W a ±30°, con ancho W = 1 en unidades adimensionales. Una fuerza externa de control idealizada, común a todas las partículas y con magnitud máxima F_{max} = 0.3, dirige el enjambre hacia la rama objetivo; el agente decide esa fuerza en cada paso. El mecanismo físico que la produce no se modela, para no atar el estudio a una tecnología de actuación concreta. La fidelidad se define en cuatro niveles acumulativos: R1 sin flujo, R2 con flujo estacionario de Poiseuille, R3 con flujo pulsátil y R4 con flujo pulsátil y movimiento browniano. El estudio se desarrolla por simulación entre febrero y diciembre de 2026.

1.1.2 Antecedentes de la investigación

Medany et al. (2025) controlaron un microrrobot impulsado por ultrasonido con DreamerV3, un algoritmo de RL basado en modelos. Entrenaron primero en un simulador y luego transfirieron la política a canales físicos, donde alcanzaron un 90 % de éxito en navegación dentro de una hora de ajuste fino. Es el trabajo base de esta tesis porque documenta el problema de la fidelidad: para operar con flujo, los autores tuvieron que rediseñar la recompensa, y en canales nuevos la política resolvió al inicio solo la mitad de las tareas. La limitación es que la brecha se observa y se corrige caso por caso; no se mide en todas las combinaciones de fidelidad de entrenamiento y de evaluación, ni se separa el efecto de cada componente físico.

Bhola et al. (2023) propusieron un marco de transferencia controlada entre entornos de distinta fidelidad para optimizar perfiles aerodinámicos con RL. Su resultado es doblemente relevante: aprender con entornos de distinta fidelidad redujo el costo computacional en más del 30 % y evitó el sobreajuste a una sola fidelidad, y los autores advierten que entrenar demasiado en la tarea de baja fidelidad puede inhibir la exploración y la generalización en la de alta. Ese riesgo, la transferencia negativa, es el que debe controlar la regla de avance de un currículo. Su limitación frente a esta tesis es que se trata de un problema de diseño, no de control secuencial, y no mide la degradación entre todos los pares de fidelidades.

Sobre el currículo, Bengio et al. (2009) mostraron que presentar los ejemplos de lo simple a lo complejo mejora la generalización y acelera la convergencia. Narvekar et al. (2020) formalizaron el currículo en RL como una secuencia de tareas y propusieron medir su beneficio con el tiempo hasta un umbral, el desempeño asintótico, el arranque inicial y la

recompensa total, y advirtieron que las tareas intermedias deben ser relevantes para la final para evitar la transferencia negativa. Portelas et al. (2020) revisaron el currículo automático y reportaron su uso para mejorar la eficiencia muestral, favorecer la generalización y optimizar la aleatorización de dominio en la transferencia de simulación a realidad. Song (2024) usó el currículo para obtener políticas robustas a distintas dinámicas del entorno, motivado por una limitación de la aleatorización de dominio (Tobin et al., 2017): a medida que la política mejora, explora cada vez menos las condiciones donde rinde mal.

Ninguno de estos trabajos ordena los niveles de fidelidad física de un mismo sistema como un currículo ni mide la brecha entre todos los pares de niveles. Ese es el vacío que aborda esta tesis.

Tabla 2. Antecedentes y su relación con esta tesis

Trabajo	Qué hace	Limitación frente a esta tesis
Medany et al. (2025)	DreamerV3 para un microrrobot por ultrasonido; simulación y transferencia a canales físicos	Brecha de fidelidad observada y corregida caso por caso (recompensa rediseñada para el flujo); no se mide entre todos los pares
Bhola et al. (2023)	Transferencia controlada entre dos fidelidades en optimización de formas	Problema de diseño, no de control secuencial; no mide la brecha entre todos los pares de fidelidades
Narvekar et al. (2020); Portelas et al. (2020)	Marco y revisión del currículo en RL	No tratan el orden de niveles de fidelidad física de un mismo sistema
Song (2024)	Currículo para robustez ante distintas dinámicas	Robótica general; no mide la brecha entre fidelidades
Tobin et al. (2017)	Aleatorización de dominio para transferir de simulación a realidad	Mezcla las condiciones; no permite medir el efecto de cada componente físico

1.1.3 Formulación del problema

Las preguntas se formulan a partir del planteamiento del proyecto aprobado por la asesora y se ordenan de modo que cada una corresponda a un objetivo específico del capítulo II.

1.1.3.1 Formulación del problema general

¿Puede un currículo progresivo de fidelidad (R1 → R2 → R3 → R4) mejorar la generalización de una política de aprendizaje por refuerzo frente al entrenamiento en un único nivel de fidelidad, con el mismo presupuesto de interacciones?

1.1.3.2 Formulación de los problemas específicos

PE1. ¿Producen los cuatro niveles de fidelidad un desempeño distinto de las políticas de control en cada par de niveles consecutivos?

PE2. ¿Cuánto se degrada una política entrenada en un nivel R_i al evaluarla en otro nivel R_j, y en qué dirección: generaliza mejor entrenar en alta fidelidad y evaluar en baja, o al revés?

PE3. ¿Reduce el currículo R1 → R4 la brecha de fidelidad media frente a la mejor política de un solo nivel, sin perder desempeño en R4?

PE4 (extensión). ¿Da un modelo interno del entorno, como el de DreamerV3, más robustez ante el cambio de fidelidad que un algoritmo sin modelo como PPO?

1.2 Justificación y alcances

1.2.1 Justificación

Práctica. Los simuladores de alta fidelidad son más costosos de ejecutar. Bhola et al. (2023) redujeron más del 30 % del costo aprovechando la baja fidelidad. Saber en qué sentido generaliza una política, de baja a alta o de alta a baja, indica en qué nivel conviene entrenar y cuándo el gasto en fidelidad no se traduce en una política mejor.

Metodológica. El estudio propone un protocolo que mide la brecha de fidelidad en una matriz de evaluación cruzada 4 × 4, con particiones de semillas disjuntas, varias semillas de entrenamiento e intervalos de confianza por bootstrap, como recomiendan Agarwal et al. (2021) para que las conclusiones en RL no dependan de una corrida afortunada. El mismo protocolo se puede aplicar a cualquier par algoritmo–simulador.

Tecnológica. El simulador, los entornos y todo el flujo de entrenamiento y evaluación quedan en un repositorio abierto y reproducible: cada resultado de este informe se recalcula con un comando y se verificó que el código del notebook y el del proyecto dan resultados idénticos.

1.2.2 Alcances

El estudio cubre un enjambre de 200 partículas en una bifurcación en Y bidimensional, los cuatro niveles de fidelidad R1–R4, PPO como algoritmo principal, el currículo R1 → R4, la matriz de evaluación cruzada 4 × 4 y, como extensión condicionada al costo, DreamerV3. Se asumen partículas no interactuantes, flujo de Poiseuille analítico, unidades adimensionales y una fuerza de control idealizada.

No cubre la validación en dispositivos físicos, ensayos in vitro o in vivo, el mecanismo físico de la actuación, geometrías tridimensionales derivadas de imágenes médicas (consideradas como etapa posterior con SimVascular si el tiempo lo permite) ni ninguna aplicación clínica. El cómputo se restringe a una CPU de 8 hilos sin GPU, lo que limita el presupuesto a unas 300 000 interacciones por corrida.

CAPÍTULO II. OBJETIVOS

2.1 Objetivo general

Reducir la pérdida de desempeño de una política de aprendizaje por refuerzo que controla un enjambre de nanopartículas magnéticas cuando cambia el nivel de fidelidad de la simulación, entrenándola con un currículo progresivo de fidelidad (R1 → R2 → R3 → R4), de modo que su brecha de fidelidad media sea al menos 0.05 menor que la de la mejor política entrenada en un único nivel, con el mismo presupuesto de interacciones con el entorno.

2.2 Objetivos específicos

Tabla 3. Objetivos específicos, actividades y evidencia

Objetivo específico	Actividad	Evidencia verificable
OE1. Obtener un entorno vascular simulado con cuatro niveles de fidelidad (sin flujo, flujo estacionario, flujo pulsátil y flujo pulsátil con movimiento browniano) en el que el desempeño de las políticas de control sea distinto entre cada par de niveles consecutivos	Diseño del simulador y corrección con variantes medidas con políticas heurísticas	Diferencia de η por par de niveles con IC corregido que excluye el 0
OE2. Identificar la dirección en que una política pierde más desempeño al cambiar de nivel, determinando si las políticas entrenadas en mayor fidelidad pierden al menos 0.05 menos de η al evaluarse en los demás niveles que las entrenadas en menor fidelidad	Entrenamiento de PPO en cada nivel y evaluación en los cuatro (matriz de evaluación cruzada 4 × 4)	FidelityGap($R_i \rightarrow R_j$) por par y brecha media por nivel de entrenamiento, con IC
OE3. Reducir en al menos 0.05 la brecha de fidelidad media con el currículo R1 → R4 sin perder más de 0.05 de η en R4 frente a la política entrenada directamente en R4	Currículo con regla de avance explícita y presupuesto igual al de un solo nivel	Diferencia de FidelityGap medio y de η en R4, con IC
OE4 (extensión). Reducir en al menos 0.05 la brecha de fidelidad media con un algoritmo basado en modelo (DreamerV3) frente a PPO, con el mismo número de interacciones	Matriz 4 × 4 con DreamerV3	Diferencia de FidelityGap medio entre algoritmos, con IC

La selección de las variables de la observación no es un objetivo de la tesis sino un medio: sirve para simplificar la observación quitando las variables que no aportan, sin bajar el desempeño en el nivel de entrenamiento, porque una observación más simple tiende a generalizar mejor y a entrenar más rápido. Del mismo modo, la alineación de la recompensa con η es una comprobación del diseño del entorno y no una hipótesis.

CAPÍTULO III. MARCO TEÓRICO

El capítulo reúne solo los conceptos que el estudio usa para medir o decidir algo; cada apartado termina indicando dónde interviene en el diseño.

3.1 Bases teóricas

Aprendizaje por refuerzo. Un agente interactúa con un entorno modelado como un proceso de decisión de Markov $\langle S, A, P, R, \rho_0 \rangle$: observa un estado, elige una acción, recibe una recompensa y el entorno pasa a un nuevo estado según la función de transición P (Portelas et al., 2020). El objetivo es una política $\pi(a \mid s)$ que maximice el retorno acumulado. En este estudio, cambiar el nivel de fidelidad cambia P sin cambiar S, A ni R: el agente ve las mismas variables y recibe la misma recompensa, pero la física que conecta la acción con el siguiente estado es distinta.

Proximal Policy Optimization (PPO). PPO es un método sin modelo de gradiente de política que limita cuánto cambia la política en cada actualización mediante un objetivo recortado: la razón entre la probabilidad nueva y la anterior de cada acción se acota al intervalo $[1 - \varepsilon, 1 + \varepsilon]$ (Schulman et al., 2017). Esa restricción lo hace estable y es la razón de su uso extendido en control continuo. Se usa la implementación de Stable-Baselines3 (Raffin et al., 2021) sobre entornos de Gymnasium (Towers et al., 2024). Andrychowicz et al. (2021) mostraron que su desempeño depende de decisiones de configuración como el tamaño del lote, el número de épocas y el coeficiente de entropía, lo que justifica la búsqueda de hiperparámetros del Sprint 5.

RL basado en modelos y DreamerV3. DreamerV3 aprende un modelo del mundo en un espacio latente y entrena la política sobre trayectorias imaginadas por ese modelo (Hafner et al., 2025). Interesa como extensión porque la pregunta de si un modelo interno del entorno da más robustez ante el cambio de fidelidad es complementaria a la del currículo, y porque es el algoritmo del trabajo base (Medany et al., 2025).

Generalización y discrepancia del simulador. La generalización en RL es el desempeño de una política en entornos que no vio durante el entrenamiento; Kirk et al. (2023) la formalizan como el desempeño sobre una distribución de contextos de prueba distinta de la de entrenamiento y señalan que en RL el sobreajuste se produce sobre el entorno, no sobre un conjunto de ejemplos. Aquí el contexto es el nivel de fidelidad, y la brecha se mide como $\text{FidelityGap}(R_i \rightarrow R_j) = \eta(\pi_{Ri}, R_i) - \eta(\pi_{Ri}, R_j)$: cuánto pierde la política entrenada en R_i al evaluarla en R_j. Es el equivalente de la brecha entre entrenamiento y validación en aprendizaje supervisado.

Aleatorización de dominio frente a currículo. La aleatorización de dominio entrena variando al azar los parámetros del simulador para que la política no dependa de ninguno en particular (Tobin et al., 2017). El currículo, en cambio, ordena las tareas de lo simple a lo complejo (Bengio et al., 2009); en RL se define como una secuencia de tareas cuyo beneficio se mide sobre la tarea final (Narvekar et al., 2020). Se elige el currículo porque los niveles R1–R4 tienen un orden natural de complejidad, porque permite atribuir el efecto a cada componente físico y porque Song (2024) muestra que la aleatorización deja de explorar las condiciones difíciles cuando la política mejora. Bhola et al. (2023) advierten el riesgo opuesto: quedarse demasiado en el nivel fácil puede inhibir la exploración y la generalización en el difícil, por lo que el currículo necesita una regla de avance explícita.

Evaluación estadística en RL. Los resultados de RL varían mucho entre semillas, y Agarwal et al. (2021) muestran que comparar promedios de pocas corridas lleva a conclusiones falsas. Recomiendan reportar intervalos de confianza por bootstrap y la variabilidad entre corridas. En este estudio cada semilla de entrenamiento es una corrida independiente, el análogo de un fold, y todas las políticas se evalúan con las mismas semillas de episodio para comparar de forma pareada.

Búsqueda de hiperparámetros. Bergstra y Bengio (2012) mostraron que la búsqueda aleatoria es más eficiente que la búsqueda en rejilla cuando pocos hiperparámetros importan, y que con 60 configuraciones al azar la probabilidad de obtener al menos una en el 5 % mejor del espacio es del 95 %. Se implementa con Optuna (Akiba et al., 2019), y la

importancia de cada hiperparámetro se estima con PED-ANOVA, que mide qué hiperparámetro distingue a las mejores configuraciones del resto (Watanabe et al., 2023).

Importancia por permutación. La importancia de una variable se estima como la caída del desempeño cuando se desordenan sus valores, lo que rompe su relación con la salida sin sacarla de su rango (Breiman, 2001). En RL se adapta permutando la variable en cada paso del episodio. Una importancia negativa indica que la política rinde mejor sin la variable, es decir, que la variable la confunde; con ese criterio se decide qué variables pueden quitarse de la observación sin perder desempeño.

3.2 Definición de términos

Tabla 4. Definiciones operativas

Término	Definición operativa en este estudio
Nivel de fidelidad	Configuración física del simulador: R1 sin flujo; R2 flujo estacionario; R3 flujo pulsátil $U(t) = U_{max}$ $(1 + A \sin 2\pi t/T)$; R4 flujo pulsátil más movimiento browniano
η (eficiencia de entrega)	Fracción del enjambre que sale por la rama objetivo, N_{obj} / N. Métrica principal
FidelityGap($R_i \rightarrow R_j$)	η de la política entrenada en R_i evaluada en R_i menos su η evaluada en R_j
Eficiencia muestral	η medio a lo largo de las evaluaciones intermedias del entrenamiento; equivale al área bajo la curva de aprendizaje
Fold	Corrida de entrenamiento independiente, definida por su semilla de PPO (1000, 1001, 1002)
Partición de ajuste	Semillas de episodio 5000–5019, usadas para tomar decisiones
Partición de reporte	Semillas de episodio 9000–9029, reservadas para resultados finales
Currículo de fidelidad	Entrenamiento secuencial R1 → R2 → R3 → R4 con una regla de avance y un presupuesto total igual al de un régimen fijo
Fuerza de control idealizada	Fuerza externa común a todas las partículas, de magnitud máxima $F_{max} = 0.3$, sin modelar su mecanismo físico
Trial	Una configuración de hiperparámetros evaluada en la búsqueda: cuatro PPO, uno por nivel, de 100 000 pasos cada uno

3.3 Hipótesis y variables

El estudio manipula deliberadamente el régimen de entrenamiento y el nivel de evaluación, manteniendo constantes el resto de los componentes del simulador, por lo que corresponde formular hipótesis contrastables. Cada una lleva un umbral fijado antes de ver los resultados.

3.3.1 Hipótesis

Tabla 5. Hipótesis y criterios de refutación

Hipótesis	Enunciado	Se refuta si
General	El currículo R1 → R4 tiene una brecha de fidelidad media al menos 0.05 menor que la mejor política entrenada en un solo nivel	La diferencia es menor a 0.05 o su IC incluye el 0
H1a	R1 y R2 producen un η distinto con la mejor política de referencia (heurística de rama)	El IC corregido de la diferencia incluye el 0
H1b	R2 y R3 producen un η distinto con la mejor política de referencia	El IC corregido de la diferencia incluye el 0

Hipótesis	Enunciado	Se refuta si
H1c	R3 y R4 producen un η distinto con la mejor política de referencia	El IC corregido de la diferencia incluye el 0
H2	Las políticas entrenadas en los niveles de mayor fidelidad (R3 y R4) tienen una brecha media al menos 0.05 menor al evaluarse en los demás niveles que las entrenadas en los de menor fidelidad (R1 y R2)	La diferencia es menor a 0.05 o su IC incluye el 0
H3	La política entrenada con currículo no pierde más de 0.05 de η en R4 frente a la entrenada directamente en R4	La pérdida en R4 supera 0.05
H4 (extensión)	DreamerV3 tiene una brecha de fidelidad media al menos 0.05 menor que PPO	La diferencia es menor a 0.05 o su IC incluye el 0

Cada hipótesis es una sola afirmación, de modo que se acepta o se refuta por sí misma. Las tres afirmaciones H1a, H1b y H1c forman una familia que se contrasta con los mismos episodios: si cada una se probara con un IC del 95 %, la probabilidad de no cometer ningún falso positivo en las tres sería $0.95^3 \approx 0.86$ y no 0.95. Para mantener el 95 % en conjunto se aplica la corrección de Bonferroni, que calcula cada intervalo al $1 - 0.05/k$; con $k = 3$ cada IC es del 98.3 %. La misma corrección se aplica a cualquier otro grupo de comparaciones que se contraste en conjunto, como los pares de la matriz 4 × 4.

El umbral de 0.05 se eligió porque es al menos cinco veces la desviación entre semillas de η dentro del nivel de entrenamiento, que no pasa de 0.008 en los Sprints 3–4: una diferencia de ese tamaño no puede atribuirse a la variabilidad entre corridas.

3.3.2 Variables

Tabla 6. Variables del estudio

Tipo	Variable	Indicador o niveles
Independiente	Régimen de entrenamiento	Un nivel (R1, R2, R3 o R4) o currículo R1 → R4
Independiente	Nivel de evaluación	R1, R2, R3, R4
Independiente	Conjunto de atributos de la observación	base (11), margen (12), sin_fase (9)
Dependiente	Generalización de la política	η por nivel; FidelityGap($R_i \rightarrow R_j$)
Dependiente	Métricas secundarias	Fracción perdida, tiempo de tránsito, esfuerzo de control, eficiencia muestral, estabilidad entre semillas
Controlada	Entorno y agente	Geometría, física v0.2, recompensa, F_{max}, presupuesto de interacciones, hiperparámetros de PPO
Aleatoria	Semilla	Semilla de PPO (fold) y semilla de cada episodio

CAPÍTULO IV. DISEÑO METODOLÓGICO

4.1 Tipo de investigación

Es una investigación aplicada con enfoque cuantitativo. Aplicada, porque busca resolver un problema concreto del entrenamiento de políticas de RL, cómo entrenarlas para que toleren

la discrepancia del simulador; cuantitativa, porque todas las respuestas se expresan con métricas numéricas medidas sobre episodios simulados.

4.2 Nivel de investigación

El nivel es explicativo-experimental. Se manipulan el régimen de entrenamiento y el nivel de evaluación y se mantiene fijo todo lo demás, por lo que las diferencias pueden atribuirse a esos factores dentro del simulador. La inferencia causal no se extiende a sistemas físicos: los cuatro niveles son simulados, R4 incluido.

4.3 Métodos de trabajo

El trabajo sigue la secuencia que propone el proyecto aprobado: corregir el simulador antes de entrenar, comprobar con un piloto que PPO aprende y que los niveles son distintos, entrenar PPO en cada nivel, construir la matriz de evaluación cruzada y recién entonces entrenar con currículo. Cada etapa se ejecuta como un sprint con un entregable verificable y cada cambio se prueba como un experimento A/B que modifica un solo componente, midiendo con las mismas semillas.

La regla de avance del currículo quedó definida antes de entrenar: la política pasa de R_k a R_{k+1} cuando su η en las semillas de ajuste supera un umbral τ en tres evaluaciones seguidas, o al agotar un tope de interacciones por nivel para que nunca se estanque. El currículo usa el mismo presupuesto total que cada régimen fijo y se considera exitoso si su η medio en R1–R4 supera al de la política entrenada solo en R4. Esta regla responde al riesgo de transferencia negativa señalado por Bhola et al. (2023) y Narvekar et al. (2020).

4.4 Población y muestra

La unidad experimental es una corrida de entrenamiento, definida por el régimen y la semilla de PPO; la unidad de observación es un episodio de evaluación. La población conceptual son todas las corridas y episodios posibles del simulador; la muestra son las semillas elegidas. En el piloto se usan tres semillas de PPO por régimen, como propone el proyecto, y la matriz 4 × 4 con currículo suma 5 regímenes × 3 semillas = 15 corridas, cada una evaluada en 4 niveles con las 30 semillas de reporte. Los episodios no se tratan como réplicas independientes: la variabilidad se reporta entre semillas de entrenamiento, para no inflar la precisión.

4.5 Tipo de diseño

El diseño es factorial con medidas repetidas: régimen de entrenamiento (R1, R2, R3, R4, currículo) por nivel de evaluación (R1–R4). Las medidas son pareadas porque todas las políticas enfrentan exactamente los mismos episodios, definidos por las semillas de evaluación, lo que elimina la variabilidad de las condiciones iniciales de la comparación.

4.6 Técnicas e instrumentos de recolección de datos

Los datos los genera el propio simulador; no hay fuentes externas ni permisos que gestionar. Cada corrida guarda su modelo, las estadísticas de normalización, la curva de aprendizaje y un archivo de metadatos con la configuración y las semillas; cada evaluación guarda una fila por episodio. El control de calidad se hace en el código: se comprueba con aserciones que las particiones de semillas no se solapan, que las semillas de los entornos coinciden con las declaradas y que el simulador del notebook reproduce exactamente al del proyecto.

4.7 Técnicas e instrumentos de análisis y procesamiento de datos

Para cada política y nivel se calcula el η medio de los episodios, su IC 95 % por bootstrap con 2000 remuestreos y la desviación estándar entre semillas de entrenamiento. Las comparaciones entre políticas son pareadas por semilla de episodio. La alineación entre recompensa y η se mide con el coeficiente de Spearman por nivel. Para prevenir fugas de información, la normalización de la observación se ajusta solo durante el entrenamiento y se congela al evaluar, y todas las decisiones se toman con la partición de ajuste.

4.8 Etapas de intervención del estudio

El diagnóstico (Sprint 1) fue el análisis exploratorio del simulador y la línea base con heurísticas. El diseño (Sprint 2) corrigió las tres fallas encontradas y congeló el entorno v0.2. La implementación (Sprints 3–5) entrenó PPO, seleccionó los atributos y ajustó los hiperparámetros. La evaluación (Sprints 6–7) corresponde a la matriz 4 × 4 y al currículo. La iteración final (Sprint 8) es la extensión con DreamerV3 si el costo lo permite.

CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS

5.1 Cronograma

Tabla 7. Cronograma por sprints

Actividad / hito	Semanas	Producto verificable
Sprint 1. EDA del simulador y línea base	Semana 4 (09/10/2026)	Informe de EDA; tabla de heurísticas por nivel
Sprint 2. Corrección del simulador y congelamiento de R1–R4	Semana 5 (16/10/2026)	Entorno v0.2 (Var3); tabla de variantes A/B
Sprint 3. Primer PPO y conjuntos de atributos	Semana 6 (23/10/2026)	9 corridas de PPO; tabla de variantes de datos
Sprint 4. Importancia por permutación	Semana 7 (30/10/2026)	Importancia en R3 y R1; elección de sin_fase
Sprint 5. Búsqueda de hiperparámetros	Semanas 8–9 (13/11/2026)	60 trials; tablero de corridas; este informe
Sprint 6. Matriz de evaluación cruzada 4 × 4	Semanas 10–11 (27/11/2026)	FidelityGap por par de niveles con IC 95 %
Sprint 7. Currículo R1 → R4	Semanas 12–13 (11/12/2026)	Comparación del currículo con la mejor política de un nivel
Sprint 8. Extensión DreamerV3 (opcional) y redacción final	Semana 14 en adelante (diciembre de 2026)	Matriz de DreamerV3; documento de tesis

5.2 Presupuesto

Tabla 8. Presupuesto

Rubro	Cantidad	Costo estimado
Computadora portátil Intel Core i7-8550U, 8 hilos, 16 GB de RAM (equipo propio)	1	S/ 0 (disponible)
Software: Python, Stable-Baselines3, Gymnasium, Optuna, PyTorch (licencias libres)	—	S/ 0
Datos: generados por el simulador propio	—	S/ 0
Cómputo en la nube o GPU	No se requiere	S/ 0

5.3 Financiamiento

El proyecto se financia con recursos propios del autor. No requiere compra de equipos, licencias ni servicios de cómputo externos.

PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL

6. Datos y material de estudio

En RL no hay un conjunto de datos fijo: los datos son las trayectorias de observación, acción y recompensa que genera el simulador cuando una política actúa en él. Por eso este capítulo describe el simulador y las trayectorias que produce.

6.1 Origen, condiciones de uso y trazabilidad

Los datos provienen de un simulador propio, escrito en Python, cuya versión v0.2 (variante Var3 del Sprint 2) está congelada desde el 16/10/2026. No usa datos de terceros, por lo que no hay licencias ni autorizaciones que gestionar. La versión de los datos queda determinada por el commit del código y la semilla de cada episodio: con ambos, cualquier trayectoria se regenera exactamente. El corte de este informe corresponde al commit 99a45e1 de la rama sprint5-busquedaHiperparametros, más los resultados del Sprint 5 del 13/11/2026.

Los parámetros físicos del entorno v0.2, en unidades adimensionales con ancho del vaso W = 1 y velocidad máxima del flujo $U_{max} = 1$, son: amplitud del pulso A = 0.9 y periodo T = 20 en R3 y R4, $F_{max} = 0.3$, coeficiente de difusión D = 0.01 en R4, paso de integración $\Delta t = 0.05$ y radio de partícula a = 0.05. Las limitaciones conocidas son la geometría bidimensional, las partículas no interactuantes, el flujo analítico y la fase inicial del pulso fija en todos los episodios.

6.2 Estructura, diccionario de datos y análisis exploratorio

Cada episodio produce una fila por paso con la observación, la acción, la recompensa y el estado del enjambre. El agente no ve las 200 partículas sino un resumen de 11 variables. El episodio termina cuando sale el 95 % del enjambre o a los 800 pasos. Con las cuatro políticas de referencia en los cuatro niveles, la partición de ajuste suma 320 episodios y unos 162 000 pasos, y la de reporte, 480 episodios y unos 244 000 pasos. No hay valores faltantes: el simulador siempre devuelve todas las variables.

Tabla 9. Diccionario de la observación

Variable	Descripción	Rango
centroid_x, centroid_y	Posición media de las partículas activas, relativa a la bifurcación	Coordenadas del vaso, en unidades de W
spread_x, spread_y	Desviación estándar de las posiciones activas	≥ 0
frac_target, frac_other, frac_active	Fracción entregada, perdida y aún activa; suman 1	[0, 1]
phase_sin, phase_cos	Fase del pulso, sen(2πt/T) y cos(2πt/T)	[−1, 1]
prev_action_x, prev_action_y	Fuerza aplicada en el paso anterior	Norma ≤ 1
control_margin (solo conjunto margen)	$F_{max} / (F_{max} + U(t))$: peso de la fuerza frente al flujo	(0, 1]
Acción	Fuerza de control 2D, recortada a norma ≤ 1 y escalada por F_{max}	Norma ≤ 1
Recompensa	$w_p\,\Delta d + w_e\,\Delta\eta_{obj} - w_m\,\Delta\eta_{otra} - w_u\,\|a\|^2$, con pesos 0.1, 1.0, 0.5 y 0.0001	—

El análisis exploratorio del Sprint 1 encontró tres fallas, que el proyecto aprobado pidió corregir antes de entrenar: R3 no se distinguía de R2, la recompensa podía explotarse (el Spearman retorno–η mínimo en R2–R3 era 0.545) y la partícula puntual se atascaba en la pared, lo que hacía fallar a la heurística perpendicular en R2. También mostró que el reparto natural del enjambre sin control es η ≈ 0.47 y que la heurística que empuja hacia la rama objetivo alcanza η entre 0.92 y 0.98 en los cuatro niveles. Dos sesgos de la métrica quedan registrados: η tiene un techo cercano a 0.95 porque el episodio termina al salir el 95 % del enjambre, y en R1, sin flujo que mueva al enjambre, η es casi binario.

6.3 Ética, privacidad y seguridad

No se usan datos personales ni de pacientes; todo es simulado y adimensional, por lo que no se requieren anonimización ni consentimiento informado. El modelo es una simplificación física y sus resultados no deben usarse para decisiones clínicas.

6.4 Preprocesamiento y control de fuga de información

El único preprocesamiento que se ajusta con datos es la normalización de la observación (VecNormalize): su media y su desviación se calculan solo con las trayectorias de entrenamiento, se guardan junto al modelo y se congelan al evaluar, de modo que la evaluación en otro nivel no filtra información de ese nivel a la política. La selección del conjunto de atributos y el recorte de la acción no dependen de los datos de evaluación. Las semillas de entrenamiento, ajuste y reporte son disjuntas y el código lo comprueba con aserciones. Todas las decisiones de este informe se tomaron con la partición de ajuste; la de reporte se reservó para los resultados finales, con la salvedad de que los Sprints 2 y 3 la usaron antes de fijar esta regla, lo que se discute como amenaza a la validez en 8.5.

7. Protocolo experimental

El protocolo se fijó antes de comparar resultados: las hipótesis y sus umbrales están en 3.3.1, y la configuración de la búsqueda, con su regla de decisión, quedó escrita en configs/train/search.yaml antes de lanzar los trials. Como el estudio no es de aprendizaje supervisado, los folds se reemplazan por semillas de entrenamiento y las particiones por semillas de episodio.

7.1 Preguntas de evaluación y criterios de éxito

Para este avance se contrastan H1a, H1b y H1c con la mejor política de referencia y se comprueba que la recompensa esté alineada con η, con un Spearman de al menos 0.9; el umbral de 0.9 traduce el pedido del proyecto de que la recompensa correlacione con η. Con la corrección de Bonferroni cada intervalo debe calcularse al 98.3 %; las diferencias de H1a (0.025) y H1c (0.083) son varias veces mayores que la amplitud de sus intervalos, de alrededor de ±0.003, por lo que la corrección no cambia su conclusión. Además se aplica la regla de decisión de la búsqueda: la mejor configuración reemplaza a la inicial solo si mejora la eficiencia muestral en al menos 0.02 y no pierde más de 0.01 de η final; se fijó así para no

adoptar una diferencia del orden de lo que varía una sola corrida. La hipótesis general, H2, H3 y H4 requieren la matriz, el currículo y DreamerV3 y se contrastarán en los sprints siguientes.

7.2 Diseño de particiones y validación

Tabla 10. Particiones por semillas

Conjunto / fold	Criterio de separación	Tamaño	Uso permitido
Entrenamiento (folds)	Semilla de PPO 1000, 1001, 1002; sus 4 entornos empiezan en semilla + 0…3	3 corridas por régimen	Entrenar; cada semilla es un fold
Ajuste	Semillas de episodio 5000–5019	20 episodios por nivel	Decidir: recompensa, atributos, hiperparámetros
Evaluación de la búsqueda	Semillas 5000–5004, subconjunto de ajuste	5 episodios por evaluación	Puntuar los trials
Banco de permutación	Semillas 5500–5509, en R3	10 episodios	Valores de reemplazo de la importancia
Reporte	Semillas de episodio 9000–9029	30 episodios por nivel	Solo resultados finales

La contaminación se previene porque ninguna semilla aparece en dos conjuntos y porque las comprobaciones están en el código, no en la disciplina del investigador. Las semillas se escriben tal cual se usan, sin sumas ocultas, para que cualquier lector pueda reproducir un episodio concreto.

7.3 Métricas y análisis estadístico

La métrica primaria es η. Las secundarias son la fracción perdida en la otra rama, el tiempo de tránsito, el esfuerzo de control, la eficiencia muestral y la estabilidad entre semillas, que son las que fija el proyecto. La incertidumbre se reporta de dos formas: el IC 95 % por bootstrap de la media de los episodios, para la variabilidad de las condiciones iniciales, y la desviación estándar entre semillas de PPO, para la variabilidad del entrenamiento (Agarwal et al., 2021). Se agrega primero promediando los episodios de cada corrida y luego entre corridas. Dos políticas se comparan sobre los mismos episodios, y una diferencia se considera relevante solo si supera el umbral fijado para esa comparación.

7.4 Baseline y variantes

Tabla 11. Baseline y variantes

ID	Modelo / configuración	Diferencia frente al baseline	Hipótesis de cambio
B-zero, B-random	Sin fuerza; fuerza al azar	Baseline mínimo	Fijan el reparto natural (η ≈ 0.47)
B-heur_branch, B-heur_perp	Empuje hacia la rama objetivo; empuje lateral cerca de la bifurcación	Baseline sólido, sin aprendizaje	PPO debe superarlas para justificar aprender
E-Var1, E-Var2, E-Var3	Recompensa corregida; + radio de partícula; + pulso fuerte y lento	Un cambio del simulador por variante	Alinear la recompensa, eliminar el atasco en la pared y separar R3 de R2

ID	Modelo / configuración	Diferencia frente al baseline	Hipótesis de cambio
P-base, P-margen, P-sin_fase	PPO entrenado en R3 con 11, 12 o 9 atributos	Atributos de la observación	Quitar las variables que dependen del nivel mejora la generalización
H-control, H-000…059	PPO con la configuración actual frente a 60 configuraciones	Hiperparámetros de PPO	Otra configuración aprende más rápido

Los controles comunes a todas las comparaciones son el entorno v0.2, la recompensa, las semillas de evaluación y, salvo en la ablación de hiperparámetros, la configuración de PPO de los Sprints 3–4.

7.5 Ingeniería de atributos o componentes

El simulador conoce las 200 posiciones, pero el agente ve un resumen; los atributos son la decisión de qué resumen darle. El centroide se mide relativo a la bifurcación para que describa la posición respecto del punto de decisión; la dispersión captura cuánto se abre el enjambre, lo que el browniano cambia en R4; las fracciones dicen cuánto salió y por dónde; la fase del pulso se codifica con seno y coseno para evitar el salto de 2π a 0; la acción previa da memoria de un paso. El margen de control, F_{max} / (F_{max} + U(t)), es un atributo derivado del dominio que expresa cuánto manda la fuerza frente al flujo.

Con ellos se compararon tres conjuntos: base (11), margen (12) y sin_fase (9). La importancia de cada grupo de atributos se mide por permutación durante el episodio: en cada paso las columnas del grupo se reemplazan por las de una observación al azar del banco de la misma política en R3, y la importancia es el η original menos el η permutado, episodio a episodio. Los atributos que codifican una misma cantidad se permutan juntos (las tres fracciones suman 1; seno y coseno son un solo ángulo).

7.6 Optimización y presupuesto de búsqueda

Tabla 12. Espacio y estrategia de la búsqueda de hiperparámetros

Parámetro	Rango / opciones	Estrategia	Presupuesto
learning_rate	$1\cdot10^{-4}$ a $1\cdot10^{-3}$, escala log	Búsqueda aleatoria (RandomSampler)	60 trials
n_steps	256, 512, 1024 por entorno	Aleatoria	4 PPO por trial, uno por nivel
batch_size	64, 128, 256	Aleatoria	100 000 pasos por nivel
n_epochs	5, 10, 20	Aleatoria	10 evaluaciones por nivel
gamma	0.99, 0.995, 0.999	Aleatoria	8 trials en paralelo; ≈ 6 h
ent_coef	$1\cdot10^{-5}$ a $1\cdot10^{-2}$, escala log	Aleatoria	Sin poda

Se fijaron la red [64, 64], cuatro entornos, gae_lambda = 0.95 y clip_range = 0.2, los valores estándar de PPO, y el conjunto sin_fase. La nota de cada trial es la eficiencia muestral promediada en los cuatro niveles. Se eligieron 60 trials porque dan un 95 % de probabilidad

de incluir una configuración del 5 % mejor del espacio (Bergstra y Bengio, 2012). No se usó poda porque, en una primera búsqueda de 20 trials, la nota parcial no ordenaba a los trials igual que la final hasta la octava evaluación (Spearman 0.80); podar en la cuarta o quinta habría eliminado a los mejores. La búsqueda se evalúa solo con las semillas 5000–5004 de la partición de ajuste; la de reporte no interviene.

7.7 Reproducibilidad y registro de experimentos

El código está en el repositorio https://github.com/BlackFermions/TesisMIA_Magnetic-Nanoswarm_RL. El entorno usa Python 3.12.7 con NumPy 2.5.3, Gymnasium 1.4.0, PyTorch 2.14.1 (CPU), Stable-Baselines3 2.9.0 y Optuna 5.0.0, con versiones fijadas en requirements.txt, sobre una CPU Intel Core i7-8550U con 8 hilos y 16 GB de RAM. La configuración de la búsqueda, incluidas todas sus semillas, está en configs/train/search.yaml. Una corrida se repite con un comando, por ejemplo python scripts/train.py --feature-sets sin_fase --condition R3 --seeds 0 para la política sin_fase con semilla de PPO 1000, y la búsqueda completa con python scripts/hpo.py --sampler random.

Cada corrida guarda en su carpeta el modelo, la normalización, la curva y un meta.json con hiperparámetros y semillas; la búsqueda guarda el estudio completo de Optuna en journal.log, lo que permite retomarla si se interrumpe; y el tablero con las 68 corridas está en results/tables/parcial_tablero.csv. No se usó MLflow porque estos archivos ya registran parámetros, métricas y artefactos de cada corrida. La reproducibilidad se verificó: el simulador del notebook, la línea base y la importancia por permutación reproducen los resultados del código del proyecto y de los sprints anteriores con diferencia cero.

8. Resultados parciales y evidencia

El corte de resultados es el 13/11/2026. La matriz 4 × 4 y el currículo no se han ejecutado, por lo que no se presentan métricas de ellos.

8.1 Estado de implementación del pipeline

Están implementados y verificados el simulador v0.2 con sus cuatro niveles, las cuatro políticas de referencia, el entrenamiento de PPO con normalización congelada, la importancia por permutación en los cuatro niveles, la búsqueda de 60 trials y el tablero de corridas. La salida verificable de cada etapa es una tabla en results/tables y una figura en results/figures, regeneradas por el notebook sem9_examen_parcial.ipynb. Quedan pendientes la matriz 4 × 4, el currículo y la extensión con DreamerV3.

8.2 Comparación cuantitativa del baseline y variantes

Tabla 13. Resultados por fold y resumen (η en R3, semillas de ajuste; eficiencia muestral para la búsqueda)

Experimento	Métrica por fold / réplica	Media ± DE	Tiempo / costo	Decisión
B-heur_branch	30 episodios de reporte	η = 0.954, IC 95 % [0.953, 0.956]	< 1 min	Referencia sólida

Experimento	Métrica por fold / réplica	Media ± DE	Tiempo / costo	Decisión
P-base	0.970 / 0.966 / 0.954	0.964 ± 0.008	19.1 min por corrida	Descartado: falla en R1 en 2 de 3 folds
P-margen	0.969 / 0.969 / 0.962	0.967 ± 0.004	19.2 min	Descartado: η = 0 en R1 en los 3 folds
P-sin_fase	0.975 / 0.962 / 0.960	0.966 ± 0.008	18.1 min	Elegido
H-control	Eficiencia por nivel 0.800 / 0.832 / 0.936 / 0.931	0.875 ± 0.069	47.8 min	Se mantiene
H-004 (mejor trial)	0.795 / 0.924 / 0.928 / 0.927	0.894 ± 0.066	65.6 min	No supera el umbral (+0.019)

PPO supera ligeramente a la mejor heurística en su nivel de entrenamiento y los tres conjuntos de atributos son equivalentes en R3, con desviaciones entre folds de 0.008 o menos. Las diferencias aparecen fuera de R3, como muestra la siguiente tabla. En la búsqueda, solo 3 de los 60 trials superaron al control, y el mejor lo hizo por 0.019, por debajo del umbral de 0.02, con una ventaja que proviene casi entera de R2 (+0.09) y un costo de tiempo 37 % mayor; por la regla de decisión se mantiene la configuración actual.

Tabla 14. η por nivel de evaluación de PPO entrenado en R3 (media ± DE entre 3 folds, semillas 5000–5019)

Conjunto	η R1	η R2	η R3	η R4	Folds con η R1 < 0.5
base	0.333 ± 0.553	0.890 ± 0.111	0.964 ± 0.008	0.888 ± 0.035	2 de 3
margen	0.000 ± 0.000	0.956 ± 0.007	0.967 ± 0.004	0.893 ± 0.006	3 de 3
sin_fase	0.969 ± 0.004	0.959 ± 0.010	0.966 ± 0.008	0.873 ± 0.006	0 de 3

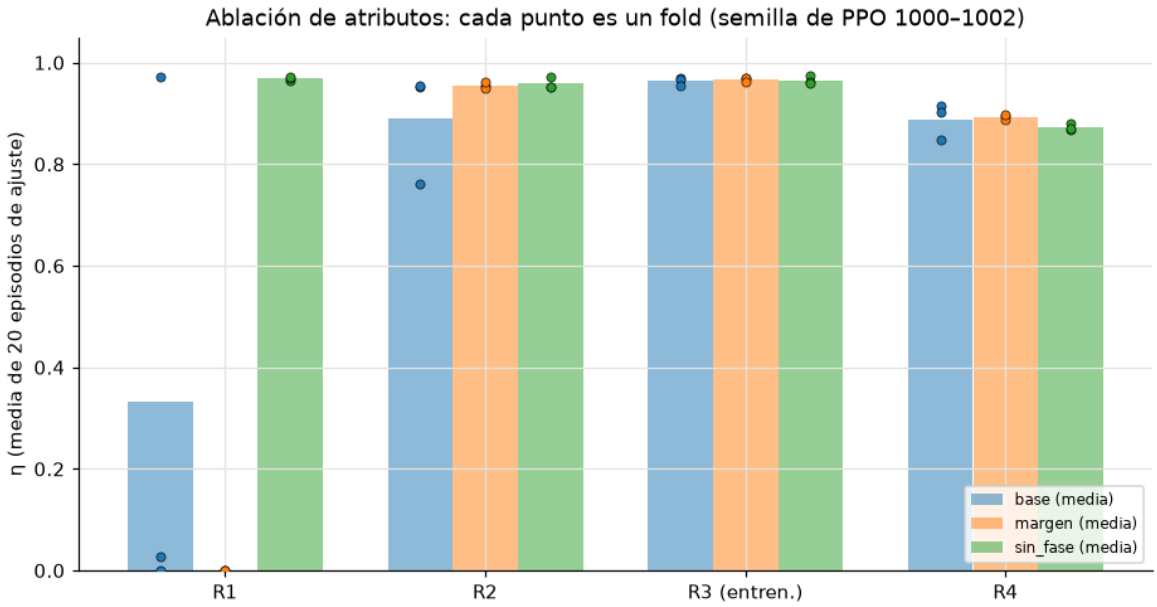


Figura 1. η por nivel de cada fold para los tres conjuntos de atributos, PPO entrenado en R3

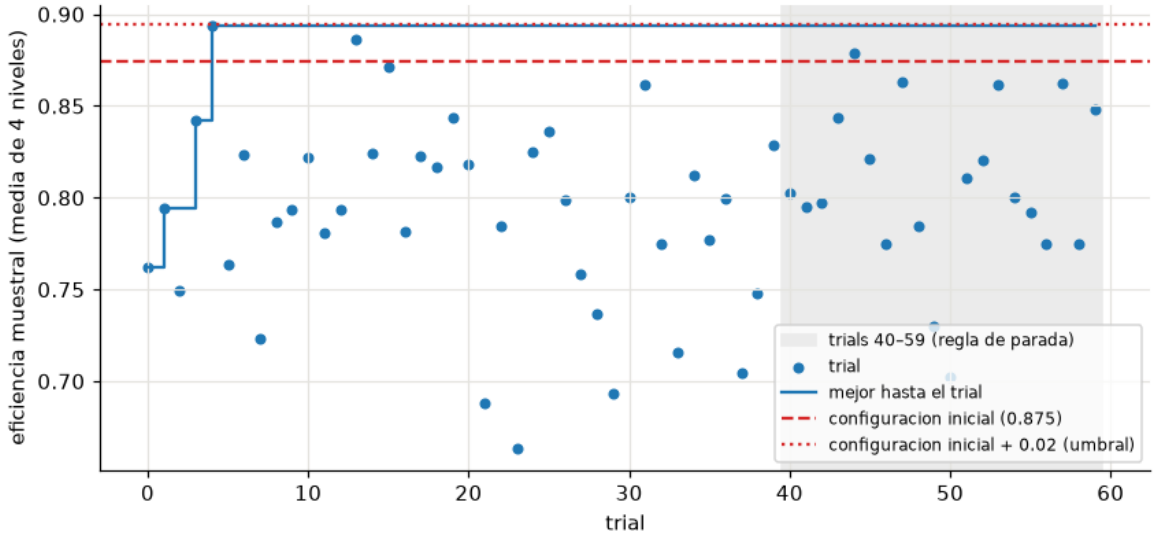


Figura 2. Eficiencia muestral de los 60 trials frente al control y al umbral de decisión

8.3 Ablaciones y análisis de sensibilidad

Tabla 15. Ablaciones (un componente por vez, mismas semillas)

Componente cambiado	Control	Resultado	Interpretación
Radio de partícula a = 0.05 (Var2)	Var1, partícula puntual	La heurística perpendicular pasa de η = 0 a 0.95 en R2 y R3	Elimina el atasco en la pared; el artefacto venía de la partícula puntual
Pulso A = 0.9, T = 20 (Var3)	Var2, A = 0.5, T = 4	La mejor heurística baja de 0.918 a 0.871 en R4; R2 y R3 siguen iguales en η	El pulso separa a R4, pero no a R3 de R2
Quitar la fase (sin_fase)	Conjunto base	Brecha media fuera de R3 de 0.260 a 0.032; R1 resuelto en 3 de 3 folds	Es el cambio que más mejora la generalización
Agregar el margen de control	Conjunto base	Brecha media 0.350; η R1 = 0 en todos los folds	El atributo derivado empeora la generalización hacia R1
6 hiperparámetros (60 trials)	Configuración de los Sprints 3–4	Eficiencia de 0.66 a 0.89; η final entre 0.93 y 0.97 en R2–R4	Cambian la velocidad de aprendizaje, no el resultado final
Mejor punto de control en vez del modelo final	Modelo final	Trials con η R1 ≥ 0.9: de 44 a 56 de 60	Mitiga el olvido en R1; cota optimista

La importancia por permutación explica el efecto de los atributos. Fuera de R3, las importancias negativas se concentran en R1: con el conjunto base, la acción previa (−0.362 en x), la fase (−0.312) y la dispersión en y (−0.281) confunden a la política cuando desaparece el flujo; con el conjunto margen, la fase y el margen llegan a −0.32. En R2 el efecto es pequeño y en R4 ninguna variable baja de −0.02. El conjunto sin_fase no tiene importancias negativas en ningún nivel. Entre los hiperparámetros, n_steps concentra 0.61 de la importancia según PED-ANOVA, y 512 por entorno, el valor actual, tiene la mejor media.

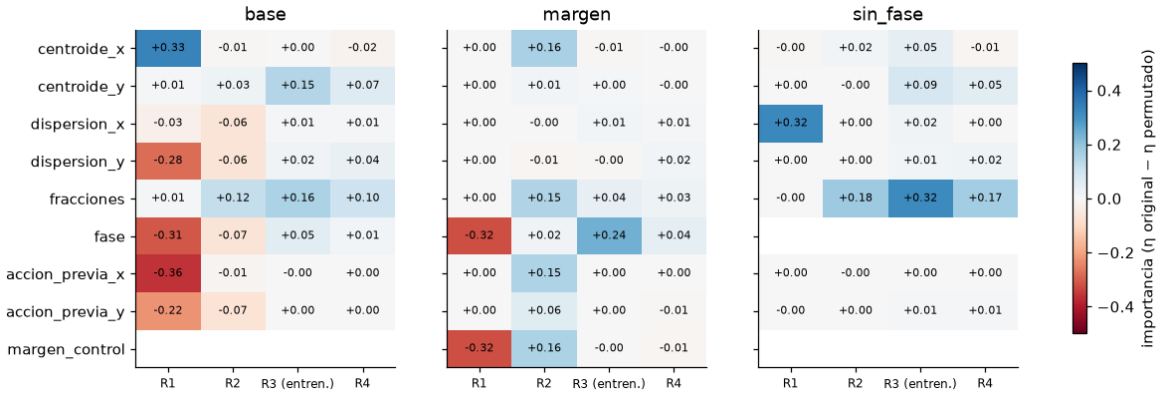


Figura 3. Importancia por permutación de cada grupo de atributos en los cuatro niveles

8.4 Sobreajuste, errores y robustez

La brecha entre entrenamiento y validación se midió en tres lugares. Entre episodios del mismo nivel no hay brecha: el η de los episodios de entrenamiento en R3 (último 10 %) y el de semillas nuevas de R3 difieren en 0.010 como máximo, por lo que PPO no memoriza episodios. Entre niveles de fidelidad sí la hay, y es la que interesa a la tesis: hacia R4 es pequeña y estable (0.07 a 0.09 en los tres conjuntos), mientras que hacia R1 depende de los atributos, con una desviación entre folds que llega a 0.55 con el conjunto base. Una validación hecha solo en el nivel de entrenamiento habría ocultado este sobreajuste.

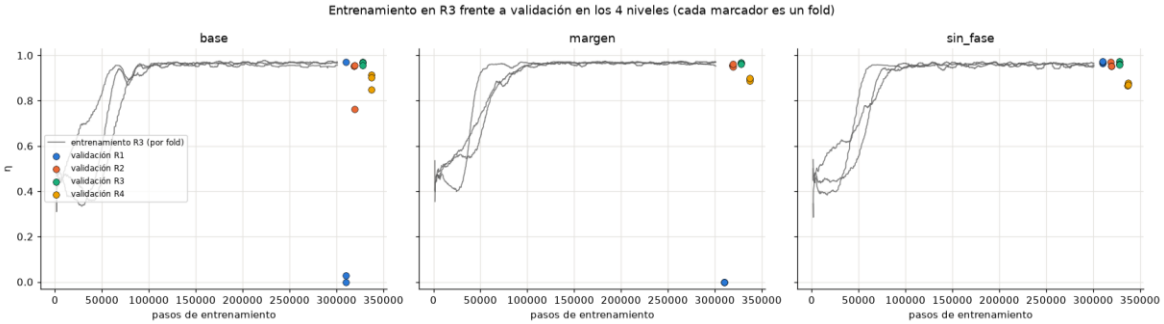


Figura 4. Curva de aprendizaje en R3 (entrenamiento) frente al η de validación en los cuatro niveles, por fold

La tercera brecha está en el tiempo. En la búsqueda, 13 de las 60 políticas entrenadas en R1 terminan con $\eta < 0.5$, y 11 de ellas habían llegado antes a $\eta \geq 0.9$: aprenden y luego olvidan, con configuraciones muy distintas entre sí. El caso de fallo es propio de R1, donde η es casi binario porque sin flujo el enjambre llega entero a una rama o no llega.

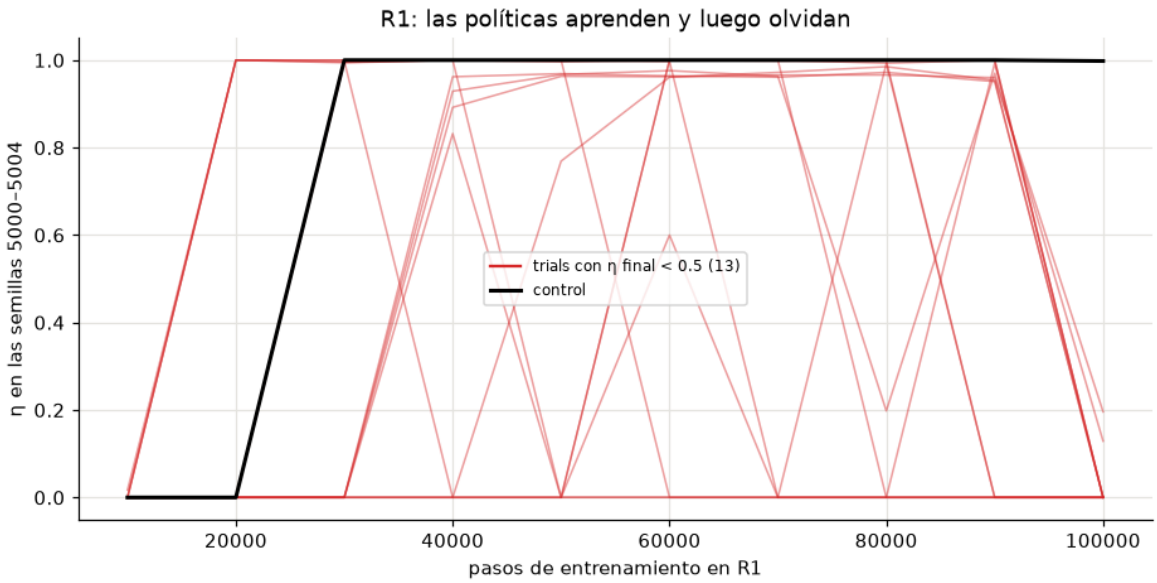


Figura 5. Evolución de η en R1 de las políticas que terminan con η < 0.5, frente al control

8.5 Interpretación y amenazas a la validez

Sobre el tamaño muestral.

Las conclusiones sobre atributos se apoyan en tres folds, cada trial de la búsqueda en una sola semilla y cada evaluación intermedia en cinco episodios. Por eso la búsqueda usó un umbral de decisión fijado de antemano y no se adoptó una configuración cuya ventaja proviene de un solo nivel.

Sobre la distinción de niveles.

R2 y R3 dan el mismo η con todas las políticas: 0.955 frente a 0.954 con la heurística de rama y 0.959 frente a 0.966 con PPO sin_fase. El pulso solo escala la rapidez del flujo y no su dirección, de modo que sin fuerza las partículas recorren los mismos caminos; con fuerza, la fuerza máxima (0.3) no vence al flujo sino que desvía al enjambre antes de la bifurcación, y en R2 esa desviación ya lleva η a su techo, cercano a 0.95 porque el episodio termina cuando sale el 95 % del enjambre. Los niveles sí difieren en el costo de llegar: el tránsito baja de 13.7 a 10.4 con la heurística de rama, aunque parte de esa diferencia puede deberse a que el pulso empieza siempre en la misma fase. En dificultad de aprendizaje no difieren: en los 60 trials la diferencia de eficiencia muestral R3 − R2 es 0.004, con IC 95 % de −0.015 a 0.023. Además, el Spearman retorno–η es 0.812, 0.86 y 0.865 en R1–R3 y solo alcanza 0.997 en R4. Con ello H1b queda refutada, mientras que H1a y H1c se cumplen, y la brecha del par R2–R3 deberá medirse también con las métricas secundarias.

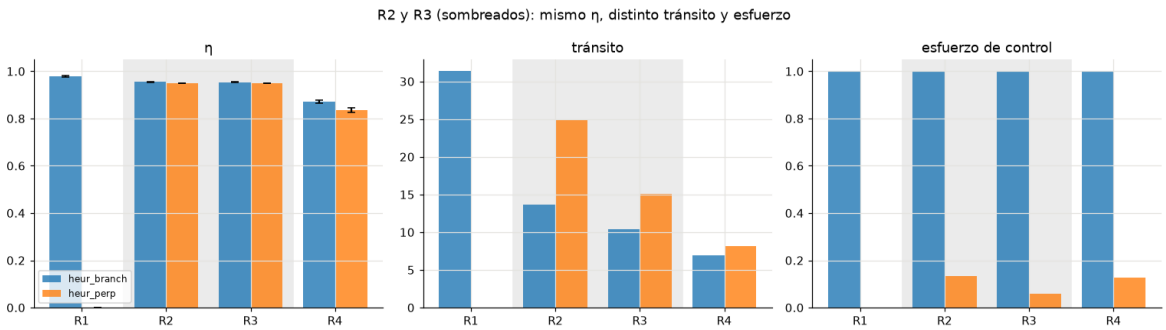


Figura 6. η, tiempo de tránsito y esfuerzo de control por nivel con las dos heurísticas; R2 y R3 sombreados

Contaminación. Las semillas de reporte se usaron en el Sprint 2 para elegir el entorno y en el Sprint 3 para comparar atributos, antes de fijar la regla de reservarlas. Todas las decisiones de este informe se tomaron con la partición de ajuste, pero los resultados finales de la tesis se medirán con un bloque nuevo de semillas que no haya intervenido en ninguna decisión.

Generalización externa. Los cuatro niveles son simulados y bidimensionales; lo que se mide es la generalización entre simuladores de distinta fidelidad, no la transferencia a un sistema físico.

Reproducibilidad e interpretabilidad. La reproducibilidad está verificada con diferencia cero frente a los sprints anteriores. La importancia por permutación debe leerse con cautela en R1, donde su desviación entre folds es cercana a 0.5 porque el efecto solo aparece en los folds cuya política falla.

9. Conclusiones del avance y próximos pasos

9.1 Conclusiones sustentadas por evidencia

Con el entorno congelado, PPO resuelve el nivel de entrenamiento (η ≈ 0.965 en R3, del orden de la mejor heurística, aunque medidas con particiones de semillas distintas) y no memoriza episodios. El sobreajuste que importa es a la física del nivel de entrenamiento, y su tamaño depende sobre todo de los atributos de la observación: quitar la fase del pulso elimina la brecha hacia R1 sin costo en R3, lo que justifica usar el conjunto sin_fase. La búsqueda de 60 configuraciones confirmó que la configuración de PPO usada desde el Sprint 3 ya estaba cerca de lo mejor del espacio y mostró que los hiperparámetros cambian la velocidad de aprendizaje, no el resultado final. H1a y H1c se cumplen y H1b queda refutada: R2 y R3 difieren en costo y no en η.

Permanecen indeterminados la dirección y la asimetría de la brecha (H2), el efecto del currículo (H3 y la hipótesis general) y la comparación con DreamerV3 (H4), que dependen de la matriz 4 × 4 y del entrenamiento con currículo.

9.2 Riesgos y plan de mitigación

Tabla 16. Riesgos priorizados

Riesgo	Impacto	Mitigación	Evidencia / responsable
Olvido de lo aprendido en R1	Alto: subestima la política entrenada en R1 en la matriz	Guardar el mejor punto de control según las semillas de ajuste y medir con las de reporte	13 de 60 trials con η R1 < 0.5 / autor
R2 y R3 iguales en η	Alto: la matriz no podrá separar ese par con la métrica principal	Medir la brecha con tránsito, esfuerzo y eficiencia muestral; decidir con la asesora si se endurece la tarea	η 0.955 frente a 0.954 / autor y asesora
Pocas semillas	Medio: conclusiones frágiles	IC 95 % por bootstrap, umbrales fijados antes y confirmación con 3 semillas	Desviación de 0.55 en R1 con base / autor
Semillas de reporte ya usadas	Medio: optimismo en los resultados finales	Bloque nuevo de semillas de reporte para la matriz y el currículo	Sprints 2–3 / autor
Costo de DreamerV3 en CPU	Bajo para la tesis: es extensión	Mantenerlo como objetivo opcional; la tesis queda completa con OE1–OE3	Proyecto aprobado / autor

9.3 Trabajo futuro para el siguiente sprint

Tabla 17. Plan de los siguientes sprints

Actividad	Entregable	Criterio de aceptación	Fecha
Confirmar las 3 mejores configuraciones con 3 semillas	Tabla de confirmación frente al control	Adoptar solo si supera al control por 0.02 en la media de 3 semillas	20/11/2026
Matriz de evaluación cruzada 4 × 4 con mejor punto de control	FidelityGap por par con IC 95 %	12 corridas completas evaluadas con semillas de reporte nuevas	27/11/2026
Decisión sobre R2–R3 con la asesora	Entrada en la bitácora	Criterio de distinción acordado antes del currículo	27/11/2026
Currículo R1 → R4	Comparación con la mejor política de un nivel	Mismo presupuesto total; contraste de H3 y de la hipótesis general	11/12/2026

REFERENCIAS

Agarwal, R., Schwarzer, M., Castro, P. S., Courville, A., y Bellemare, M. G. (2021). Deep reinforcement learning at the edge of the statistical precipice. *Advances in Neural Information Processing Systems*, *34*, 29304–29320.

Akiba, T., Sano, S., Yanase, T., Ohta, T., y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2623–2631).

Andrychowicz, M., Raichuk, A., Stańczyk, P., Orsini, M., Girgin, S., Marinier, R., Hussenot, L., Geist, M., Pietquin, O., Michalski, M., Gelly, S., y Bachem, O. (2021). What matters for on-policy deep actor-critic methods? A large-scale study. En *International Conference on Learning Representations*.

Bengio, Y., Louradour, J., Collobert, R., y Weston, J. (2009). Curriculum learning. En *Proceedings of the 26th International Conference on Machine Learning* (pp. 41–48).

Bergstra, J., y Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, *13*, 281–305.

Bhola, S., Pawar, S., Balaprakash, P., y Maulik, R. (2023). Multi-fidelity reinforcement learning framework for shape optimization. *Journal of Computational Physics*, *482*, 112018. https://doi.org/10.1016/j.jcp.2023.112018

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32.

Hafner, D., Pasukonis, J., Ba, J., y Lillicrap, T. (2025). Mastering diverse control tasks through world models. *Nature*, *640*, 647–653.

Kirk, R., Zhang, A., Grefenstette, E., y Rocktäschel, T. (2023). A survey of zero-shot generalisation in deep reinforcement learning. *Journal of Artificial Intelligence Research*, *76*, 201–264.

Medany, M., Piglia, L., Achenbach, L., Mukkavilli, S. K., y Ahmed, D. (2025). Model-based reinforcement learning for ultrasound-driven autonomous microrobots. *Nature Machine Intelligence*, *7*, 1076–1090. https://doi.org/10.1038/s42256-025-01054-2

Narvekar, S., Peng, B., Leonetti, M., Sinapov, J., Taylor, M. E., y Stone, P. (2020). Curriculum learning for reinforcement learning domains: A framework and survey. *Journal of Machine Learning Research*, *21*(181), 1–50.

Portelas, R., Colas, C., Weng, L., Hofmann, K., y Oudeyer, P.-Y. (2020). Automatic curriculum learning for deep RL: A short survey. En *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence* (pp. 4819–4825).

Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., y Dormann, N. (2021). Stable-Baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, *22*(268), 1–8.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., y Klimov, O. (2017). *Proximal policy optimization algorithms* (arXiv:1707.06347). arXiv.

Song, Y. (2024). *Robust reinforcement learning via curricular learning* [Tesis doctoral, Carnegie Mellon University]. CMU-RI-TR-24-75.

Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., y Abbeel, P. (2017). Domain randomization for transferring deep neural networks from simulation to the real world. En *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems* (pp. 23–30).

Towers, M., Kwiatkowski, A., Terry, J., Balis, J. U., De Cola, G., Deleu, T., Goulão, M., Kallinteris, A., Krimmel, M., KG, A., Perez-Vicente, R., Pierré, A., Schulhoff, S., Tai, J. J., Tan, H., y Younis, O. G. (2024). *Gymnasium: A standard interface for reinforcement learning environments* (arXiv:2407.17032). arXiv.

Watanabe, S., Bansal, A., y Hutter, F. (2023). PED-ANOVA: Efficiently quantifying hyperparameter importance in arbitrary subspaces. En *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence* (pp. 4389–4396).

ANEXOS

El cronograma detallado está en 5.1, el diccionario de datos en 6.2 y la evidencia de ejecución (repositorio, comandos, registros y figuras) en 7.7 y en el capítulo 8. Este apartado incluye la matriz de consistencia y el registro resumido de corridas.

Anexo A. Matriz de consistencia

Tabla 18. Matriz de consistencia

Problema	Objetivo	Hipótesis	Variable	Indicador medible
PG. ¿Mejora el currículo R1 → R4 la generalización frente a un solo nivel?	OG. Reducir en ≥ 0.05 la brecha de fidelidad media con el currículo	General	Régimen de entrenamiento	FidelityGap medio; diferencia ≥ 0.05 con IC 95 %
PE1. ¿Difiere el desempeño entre cada par de niveles consecutivos?	OE1. Obtener cuatro niveles con desempeño distinto entre pares consecutivos	H1a, H1b, H1c	Nivel de fidelidad	Diferencia de η por par con IC corregido (Bonferroni)
PE2. ¿Cuánto y en qué dirección se degrada la política?	OE2. Identificar la dirección de mayor pérdida al cambiar de nivel	H2	Nivel de entrenamiento y de evaluación	Brecha media de R3–R4 frente a R1–R2
PE3. ¿Reduce el currículo la brecha sin perder η en R4?	OE3. Reducir la brecha ≥ 0.05 sin perder > 0.05 de η en R4	General, H3	Régimen de entrenamiento	Reducción ≥ 0.05; pérdida en R4 ≤ 0.05
PE4. ¿Da DreamerV3 más robustez que PPO?	OE4. Reducir la brecha ≥ 0.05 con DreamerV3 frente a PPO	H4	Algoritmo	FidelityGap medio de cada algoritmo

Anexo D. Registro de corridas

Extracto del tablero completo de 68 corridas (results/tables/parcial_tablero.csv). El commit de todas es 99a45e1 de la rama sprint5-busquedaHiperparametros, con el entorno v0.2.

Tabla 19. Registro resumido de corridas

run_id	Commit / datos	Seed / split	Métrica	Artefacto
B-heur_branch	99a45e1 / v0.2	Episodios 9000–9029 / reporte	η R3 = 0.954 ± 0.004	results/tables/parcial_baseline_episodios.csv
P-base	99a45e1 / v0.2	PPO 1000–1002; 5000–5019 / ajuste	η R3 = 0.964 ± 0.008	experiments/pilot/base_R3_s*
P-margen	99a45e1 / v0.2	PPO 1000–1002; 5000–5019 / ajuste	η R3 = 0.967 ± 0.004	experiments/pilot/margen_R3_s*
P-sin_fase	99a45e1 / v0.2	PPO 1000–1002; 5000–5019 / ajuste	η R3 = 0.966 ± 0.008	experiments/pilot/sin_fase_R3_s*
H-control	99a45e1 / v0.2	PPO 1000; 5000–5004 / ajuste	Eficiencia 0.875 ± 0.069	experiments/hpo/control
H-004	99a45e1 / v0.2	PPO 1000; 5000–5004 / ajuste	Eficiencia 0.894 ± 0.066	experiments/hpo/random/trial_004
H-013	99a45e1 / v0.2	PPO 1000; 5000–5004 / ajuste	Eficiencia 0.886 ± 0.064	experiments/hpo/random/trial_013
H-023 (peor)	99a45e1 / v0.2	PPO 1000; 5000–5004 / ajuste	Eficiencia 0.663 ± 0.223	experiments/hpo/random/trial_023

Anexo E. Enlace Github

https://github.com/BlackFermions/TesisMIA_Magnetic-Nanoswarm_RL/blob/sprint5-busquedaHiperparametros/notebooks/sem9_examen_parcial.ipynb